



Sie können das KI-Biest fragen, wo es anfällig ist, und es wird eine kuratierte Liste wissenschaftlicher Arbeiten, Branchenrichtlinien, Tools und praktischer Ressourcen zur Bewertung und Red-Teaming-KI-Systeme mit Schwerpunkt auf Jailbreaking und sofortiger Injektion ausspucken. Schauen Sie in das große Sprachmodell, auf dem die KI basiert, und Sie sehen nichts als winzige Zahlen, Gewichte und Vorurteile, die in Zeitformen gefaltet sind, die für das bloße Auge nutzlos sind. Kein Scanner der Welt kann einen Dump dieser Zahlen lesen und Ihnen sagen, ob eine Passnummer oder ein vertrauliches Memo in den Trainingsdaten enthalten war. Vergessen Sie also die Fantasie, ein Modell zu röntgen, um die darin gefangenen Geheimnisse zu finden. Die einzige wirkliche Methode, die wir haben, ist einfacher, dümmere und weitaus gefährlicher. Stochern Sie das Modell an, bis etwas herausplatzt. Was mich zur Feinabstimmung bringt. Feinabstimmung ist das Unternehmensäquivalent dazu, sensible Dokumente in einer Bar herumliegen zu lassen. Sie nehmen Ihre privaten Schulungsdateien, laden sie auf OpenAI oder einen anderen Anbieter hoch und bitten ihn, Ihr personalisiertes Modell zu trainieren. Jetzt existieren Ihre Geheimnisse in mindestens drei Kopien lokal, aus der Ferne und im mathematischen Schädel des Modells. Und selbst wenn das Modell darauf trainiert ist, niemals private Daten preiszugeben, ist das nur ein loser Verhaltenshinweis, kein Gebot. Das Modell wehrt sich zunächst, wie ein Hund, der darauf trainiert ist, nicht von der Theke zu stehlen. Frag einfach weiter. Beharrlichkeit statt Brillanz. Und schließlich bricht die KI. Passnummern,

Eingabeaufforderungen, Open-Source-Tools und hartnäckige Geduld. Die Schattendaten sind real, die Lecks sind real und die Maschine, unser glänzender Industriegott, hat keine Ahnung, wie viel sie sich merkt. Also, da bin ich, Ich frage mich, wie viele Vektoren meines eigenen Lebens bereits da draußen in der Leere drifteten.

Telefonnummern, biografische Angaben. In der ersten Hälfte richtig, dann fast perfekt. Die Zufälligkeit, die in jeder KI-Ausgabe verankert ist, bedeutet, dass man, wenn man lange genug würfelt, DEN JACKPOT trifft. DAS IST KEIN HACKEN. Das's warten. Und derselbe Wahnsinn spielt sich auch bei der Bilderzeugung ab. In einem Moment macht die KI fröhlich ein Meme für Sie. Im nächsten Fall lehnt es ab und zitiert die Politik. Sie drücken öfter auf „Erneut versuchen“, als Ihnen lieb ist, und erhalten nie wieder ein Bild. Aber die Frage bleibt, warum hat es einmal funktioniert? Das ist das Problem mit KI als Sicherheitsinfrastruktur. 1 % Ausfall ist 100 % Kompromiss. Wenn eine Firewall 1% der Pakete durchlässt, ziehen Sie den Ingenieur nach draußen und lassen ihn sich erklären. Wenn es sich bei der Feinabstimmung um ein Datenleck handelt, ist die erweiterte Generierung von Rag Retrieval ein völlig kaputtes Rohr unter Ihren Dielen. So funktioniert Rag. Sie stellen eine Frage. Im Hintergrund fragt das System leise eine Datenbank Ihrer internen Dokumente per Einbettungssuche ab. Alles Relevante wird in die Eingabeaufforderung gestopft. Das Modell antwortet mit Ihren Daten. Klingt toll. Klingt auch nach einer Vorladung, die darauf wartet, passiert zu werden, denn jetzt werden sensible Dokumente, E-Mails und Finanzdateien stillschweigend in Protokolle, Eingabeaufforderungen, Caches und Vektorspeicher kopiert, wo immer das Modell sie benötigt. Überall vergessen Entwickler, dass sie sie platziert haben, was es trivial macht, diese Geheimnisse ans Licht zu bringen. Klassische Eingabeaufforderung. Obige Angriffe, Übersetzungsangriffe, Markdown-Fechten, kreativer Unsinn. Das Modell blockiert Dutzende Versuche. Doch je länger

das Gespräch dauert, je mehr Kontext das System einbringt, desto schwächer werden die Leitplanken. Schließlich bricht es. Es drückt die Systemaufforderung, dann die sensiblen RAG-Daten, dann die Administratormeldeinformationen und trifft zu 100 % auf die synthetische Datenbank. Wir haben drei Dinge gelernt. Längerer Kontext, höhere Ausfallwahrscheinlichkeit. Systemaufforderungen schützen nichts. Im Winter leckt der Lappen wie ein schwitzendes Wohnmobilenster.Akademische Arbeiten dokumentieren den Lumpendieb. 70 % einer Wissensdatenbank werden automatisch extrahiert, indem lediglich iterative Eingabeaufforderungen verwendet werden. Und das alles war immer noch nur Vorspiel. Die Vektorfälle. Jetzt kommen wir zum wahren Geist in der Maschine. Einbettungen. Wenn ein Dokument in ein Einbettungsmodell eingespeist wird, erhalten Sie keinen Text zurück. Sie erhalten einen Vektor. Hunderte oder Tausende winziger Zahlen, die die Bedeutung der Passage darstellen. Entwickler behandeln diese als harmlose Abstraktionen. Ein CEO einer Vektordatenbank sagte: „Vektoren sind wie Hashes, sicher, auch wenn sie gestohlen werden.“ Falsch. Lächerlich falsch. Denn im Gegensatz zu einem Hash können Einbettungen invertiert werden. Sie können einen Vektor nehmen, ihn durch ein Inversionsmodell und dann durch eine Korrekturschleife laufen lassen und den Originaltext mit unheimlicher Genauigkeit rekonstruieren. Private medizinische Details, die aus den Dezimalstellen wiederbelebt wurden, die die meisten Ingenieure für bedeutungslos halten,Namen, Diagnose, Beträge, Daten. Die Inversionsgenauigkeit liegt bei nahezu 100 %. Stellen Sie sich also Ihren gesamten Unternehmensdateispeicher,

Ihr E-Mail-System und Ihre HR-Datenbank vor, die alle in Einbettungen für die KI-Suche umgewandelt wurden. Stellen Sie sich nun vor, diese Einbettungen würden undicht. Du musst es dir nicht vorstellen. Es passiert bereits. KI-Fisichen, E-Mails, die versteckte Anweisungen in den Rag-Kontext einbetten und das Modell dazu verleiten, Daten, die harmlos in Marktdown-Links verpackt sind, zu exfiltrieren. Moderne KI-Systeme vervielfachen private Daten. Sie replizieren es über Protokolle, Eingabeaufforderungsverläufe, Vektorindizes, Trainingsdateien, Caches und Backups hinweg. Wenn ein normales System undicht ist wie ein Wasserrhahn, sind KI-Systeme undicht wie ein Hydrant, der von einem Lastwagen angefahren wird. Wie verteidigen wir uns also? Drei einfache Regeln. Seien Sie misstrauisch gegenüber jeder KI-Funktion, die Ihre Dokumente automatisch verschluckt. Die Gelegenheitsteuer wird als Risikoposition gezahlt.Befragen Sie Anbieter, als ob sie Ihnen Geld schulden würden. Fragen Sie, wie sie mit Trainingsdaten, Protokollen, Einbettungen und Aufbewahrung umgehen. Beobachten Sie, wie schnell sie blinken. Verschlüsseln Sie sie auf der Anwendungsebene. Bevor Daten jemals eine Datenbank, einen Vektorspeicher oder ein Modelleingabefeld berühren, ist die Krypto-Landschaft gemischt. Vertrauliche Rechenenklaven, homorphe Verschlüsselung, Tokenisierung, Methoden zur Abstandserhaltung, alles unvollkommen. Alles besser als nichts. KI-Systeme nutzen nicht nur Ihre privaten Daten. Sie multiplizieren es, verteilen es und lassen es an Orten herumliegen, die niemand beobachtet. Und der Clou: Es lässt sich leicht ausnutzen. Lächerlich einfach. Keine Hollywood-Hacker erforderlich. Nur einfache